


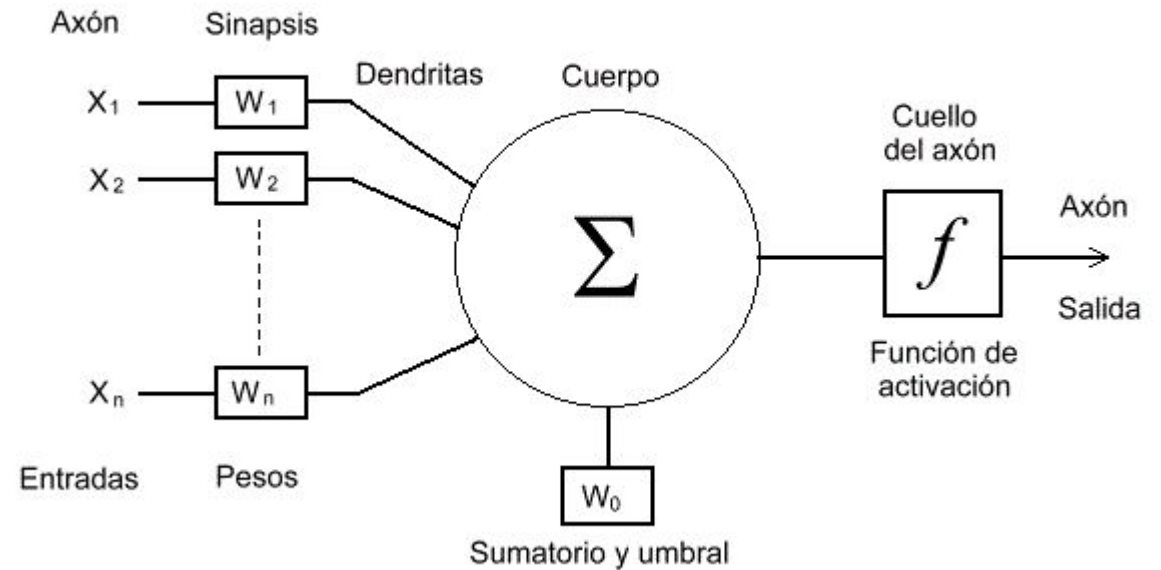

Redes Neuronales

Una introducción...

Frank Rosenblatt, en la década de los 50, se inspira en las neuronas biológicas...



...para definir lo que se conoce como neurona artificial...



- **Núcleo celular:** Zona de procesamiento.
- **Dendritas:** Zonas receptoras.
- **Axón:** Líneas de transmisión.
- **Axones terminales (sinapsis):** Conexiones excitadoras o inhibitoras.

$$x_1 = 23, x_2 = 68, x_3 = 170$$

$$w_1 = 1, w_2 = 2, w_3 = 3$$

$$23(1) + 68(2) + 170(3) = 669$$

El Perceptrón

- Neurona artificial o unidad básica de inferencia en forma de discriminador lineal.

$$y = f(\vec{w} \cdot \vec{x}) = f\left(\sum_j w_j x_j\right)$$


Donde:

- x_j : característica j de la muestra.
- w_j : peso sináptico
- f : función de activación

Id	Sem Ant	Oro	Tend	P prox Sem
1	1816	1288	1	1290
2	1810	1276	1	1295
3	1860	1290	0	1290
4	1799	1277	0	1280
5	1790	1280	1	1286
6	1877	1270	0	1277

PERCEPTRÓN

Presentación



Salida esperada: 1290



Del Prof. Pablo Sanz



Id	Sem Ant	Oro	Tend	P prox Sem
1	1816	1288	1	1290
2	1810	1276	1	1295
3	1860	1290	0	1290
4	1799	1277	0	1280
5	1790	1280	1	1286
6	1877	1270	0	1277

PERCEPTRÓN

Primera lectura





Error: 590

Id	Sem Ant	Oro	Tend	P prox Sem
1	1816	1288	1	1290
2	1810	1276	1	1295
3	1860	1290	0	1290
4	1799	1277	0	1280
5	1790	1280	1	1286
6	1877	1270	0	1277

PERCEPTRÓN



Modificación de pesos



Id	Sem Ant	Oro	Tend	P prox Sem
1	1816	1288	1	1290
2	1810	1276	1	1295
3	1860	1290	0	1290
4	1799	1277	0	1280
5	1790	1280	1	1286
6	1877	1270	0	1277

PERCEPTRÓN

Entrenamiento (FP)




Error: 590

Id	Sem Ant	Oro	Tend	P prox Sem
1	1816	1288	1	1290
2	1810	1276	1	1295
3	1860	1290	0	1290
4	1799	1277	0	1280
5	1790	1280	1	1286
6	1877	1270	0	1277

PERCEPTRÓN


Entrenamiento (FP)



Id	Sem Ant	Oro	Tend	P prox Sem
1	1816	1288	1	1290
2	1810	1276	1	1295
3	1860	1290	0	1290
4	1799	1277	0	1280
5	1790	1280	1	1286
6	1877	1270	0	1277

PERCEPTRÓN

Entrenamiento (FP)





Error Acum: 4789

Id	Sem Ant	Oro	Tend	P prox Sem
1	1816	1288	1	1290
2	1810	1276	1	1295
3	1860	1290	0	1290
4	1799	1277	0	1280
5	1790	1280	1	1286
6	1877	1270	0	1277

PERCEPTRÓN

Ajuste de pesos
¿Fuerza bruta?






Id	Sem Ant	Oro	Tend	P prox Sem
1	1816	1288	1	1290
2	1810	1276	1	1295
3	1860	1290	0	1290
4	1799	1277	0	1280
5	1790	1280	1	1286
6	1877	1270	0	1277

PERCEPTRÓN



Ajuste de pesos (BP)



Id	Sem Ant	Oro	Tend	P prox Sem
1	1816	1288	1	1290
2	1810	1276	1	1295
3	1860	1290	0	1290
4	1799	1277	0	1280
5	1790	1280	1	1286
6	1877	1270	0	1277


PERCEPTRÓN

Ajuste de pesos (BP)




Error Acum: 1789
Backpropagation






Id	Sem Ant	Oro	Tend	P prox Sem
1	1816	1288	1	1290
2	1810	1276	1	1295
3	1860	1290	0	1290
4	1799	1277	0	1280
5	1790	1280	1	1286
6	1877	1270	0	1277

Descenso del Gradiente




Error Acum: 4789

Descenso del Gradiente




$$J = 1/2 \cdot \sum (y - y')^2$$

Descenso del Gradiente




Id	Sem Ant	P prox Sem
1	1816	1290
2	1810	1295
3	1860	1290
4	1799	1280
5	1790	1286
6	1877	1277

$$J = 1/2 \cdot \sum (y - y')^2$$




Descenso del Gradiente




Id	Sem Ant	P prox Sem
1	1816	1290
2	1810	1295
3	1860	1290
4	1799	1280
5	1790	1286
6	1877	1277

$$J = 1/2 \cdot \sum (y - y')^2$$




Descenso del Gradiente




Id	Sem Ant	P prox Sem
1	1816	1290
2	1810	1295
3	1860	1290
4	1799	1280
5	1790	1286
6	1877	1277

$$J = 1/2 \cdot \sum (y - y')^2$$




Descenso del Gradiente




Id	Sem Ant	P prox Sem
1	1816	1290
2	1810	1295
3	1860	1290
4	1799	1280
5	1790	1286
6	1877	1277

$$J = 1/2 \cdot \sum (y - y')^2$$




Descenso del Gradiente




Id	Sem Ant	P prox Sem
1	1816	1290
2	1810	1295
3	1860	1290
4	1799	1280
5	1790	1286
6	1877	1277

$$J = 1/2 \cdot \sum (y - y')^2$$




Descenso del Gradiente



Id	Sem Ant	P prox Sem
1	1816	1290
2	1810	1295
3	1860	1290
4	1799	1280
5	1790	1286
6	1877	1277

$$J = 1/2 \cdot \sum (y - y')^2$$





Descenso del Gradiente



Id	Sem Ant	P prox Sem
1	1816	1290
2	1810	1295
3	1860	1290
4	1799	1280
5	1790	1286
6	1877	1277


$$J = 1/2 \cdot \sum (y - y')^2$$

Descenso del Gradiente



Id	Sem Ant	P prox Sem
1	1816	1290
2	1810	1295
3	1860	1290
4	1799	1280
5	1790	1286
6	1877	1277

$$J = 1/2 \cdot \sum (y - y')^2$$




Descenso del Gradiente




Id	Sem Ant	P prox Sem
1	1816	1290
2	1810	1295
3	1860	1290
4	1799	1280
5	1790	1286
6	1877	1277

$$J = 1/2 \cdot \sum (y - y')^2$$




Descenso del Gradiente



Id	Sem Ant	P prox Sem
1	1816	1290
2	1810	1295
3	1860	1290
4	1799	1280
5	1790	1286
6	1877	1277

$$J = 1/2 \cdot \sum (y - y')^2$$

Descenso del Gradiente





Id	Sem Ant	P prox Sem
1	1816	1290
2	1810	1295
3	1860	1290
4	1799	1280
5	1790	1286
6	1877	1277

$$J = 1/2 \cdot \sum (y - y')^2$$


Id	Sem Ant	Oro	Tend	P prox Sem
1	1816	1288	1	1290
2	1810	1276	1	1295
3	1860	1290	0	1290
4	1799	1277	0	1280
5	1790	1280	1	1286
6	1877	1270	0	1277

Descenso del Gradiente



Error Acum: 50

Descenso del Gradiente



Id	Sem Ant	P prox Sem
1	1816	1290
2	1810	1295
3	1860	1290
4	1799	1280
5	1790	1286
6	1877	1277

$$J = 1/2 \cdot \sum (y - y')^2$$


Para llegar a este punto, se han realizado 4 “saltos:

Al tamaño de estos saltos se les conoce como: **Tasa de Aprendizaje (Learn Rate - α)**


α pequeñas = fuerza bruta

α grandes = difícil de hallar el mínimo global


Descenso del Gradiente



- Útil cuando la función de coste es convexa.
- Puede caer en óptimos locales si la función no es convexa.
- La mayoría de las veces se requieren de modelos no lineales, que requieren a su vez funciones de pérdida que son no convexas.




Recordatorios...



- Una función es **CÓNCAVA** o presenta su concavidad hacia abajo cuando dados dos puntos cualesquiera el segmento que los une queda por debajo de la curva.
- Una función es **CONVEXA** o presenta su concavidad hacia arriba si dados dos puntos de la curva el segmento que los une queda por encima de la curva.
- Los puntos en los que la curvatura pasa de cóncava a convexa o viceversa se llaman **PUNTOS DE INFLEXIÓN**

- **Definición #1:** Una función $y=f(x)$ es CÓNCAVA en un intervalo cuando las tangentes a la curva en los puntos de dicho intervalo quedan por encima de la curva.
- **Definición #2:** Una función $y=f(x)$ será CONVEXA en un intervalo cuando las tangentes a la curva en los puntos de dicho intervalo quedan por debajo de la curva.

Recordatorios...



De una forma más concreta:

Sea una función f que posea primera y segunda derivada diferentes de cero, es decir:


$$\exists f'(x) \neq 0$$

$$\exists f''(x) \neq 0$$

Entonces:

- **Definición #1:** Una función $y=f(x)$ es CÓNCAVA si $f''(x) < 0$
- **Definición #2:** Una función $y=f(x)$ será CONVEXA si $f''(x) > 0$

Recordatorios...



Ejemplo:

$$\text{Sea } f(x) = x^3 + 2x^2 + 1$$

Tenemos que:

f es cóncava en $(-\infty, -\frac{2}{3})$ y

f es convexa en $(-\frac{2}{3}, +\infty)$


Donde: $-\frac{2}{3}$ es el punto de inflexión.

Esto es porque:


- $f'(x) = 3x^2 + 4x$ y $f''(x) = 6x + 4$ son diferentes de cero.
- $f''(x) = 0 \rightarrow 6x + 4 = 0 \rightarrow x = -\frac{2}{3}$

Recordatorios...

Función no convexa vs Función convexa




a) Función no convexa



b) Función convexa

Descenso del Gradiente estocástico




- Útil cuando la función de coste es no convexa
- La estrategia es igual que la anterior, pero ajustando los pesos por cada muestra en lugar de esperar a consumir todas las muestras.




Id	Sem Ant	P prox Sem
1	1816	1290
2	1810	1295
3	1860	1290
4	1799	1280
5	1790	1286
6	1877	1277

$$J = y - y'$$

Descenso del Gradiente / estocástico



- Ambos métodos presentan ventajas y desventajas
- Para el descenso del gradiente se requiere de suficiente memoria de computador durante el proceso.
- Para el descenso del gradiente estocástico se requiere de un rápido acceso a disco.
- Para lidiar un poco con las ventajas/desventajas de ambos utilizamos una estrategia híbrida conocida como **minibatch**.




Id	Sem Ant	P prox Sem
1	1816	1290
2	1810	1295
3	1860	1290
4	1799	1280
5	1790	1286
6	1877	1277

Una función de coste no convexa

Descenso del Gradiente / estocástico

¡En 2 o más dimensiones es similar!



Funciones de coste

- La función de coste depende del tipo de problema a resolver: regresión o clasificación.
- Una función que suele funcionar muy bien en problemas de clasificación es la entropía cruzada

$$J(p, q) = \sum_x p(x) \log(q(x))$$

Función de entropía cruzada:


- * Cuantifica la diferencia entre dos distribuciones de probabilidad.
- * Describe la pérdida entre dos distribuciones de probabilidad.

Retomaremos esto más adelante...

Hasta los momentos...

- Perceptrón
- Forward Propagation
- Algunas funciones de coste
- Descenso del gradiente
- Backpropagation

Redes Neuronales



- Cada neurona tiene sus propios pesos/parámetros. En aplicaciones comunes suelen ser desde miles a millones de parámetros para toda la red.
- Deep Learning es encontrar esos pesos de manera eficiente, bajo la condición de realizar correctamente una tarea objetivo.
- Existen diversas arquitecturas de redes neuronales.
- Se pueden usar para regresión y clasificación.

A continuación...

- Redes neuronales, clasificación
- Funciones de activación
- Métricas y medidas de rendimiento
- Ejemplos avanzados
- Procesamiento de imágenes
- Introducción a las redes neuronales convolucionales